SÉANCE 4 — DU PROBLÈME AU PROJET DATA

SkillMatch — Deck & Dossier de Cadrage

Plateforme d'analyse comparative CV/Offres d'emploi & recommandation de progression pour juniors Data

1. PARTIE 1 : COMPRENDRE LE PROBLÈME

Personas Rattachés au Problème

Persona 1 (Principal) : Yassine, 24 ans — Étudiant en dernière année d'école d'ingénieur (recherche 1er CDI / Alternance Data).

- **Objectif :** Décrocher un poste aligné avec ses compétences techniques.
- **Frustration :** Ne sait pas si ses compétences correspondent aux attentes réelles du marché ni quoi développer en priorité.

> *« J'envoie des CV, mais je ne sais jamais exactement pourquoi je suis refusé ni ce qu'il me manque pour convaincre. »*

Persona 2 (Secondaire) : Claire, 28 ans — Jeune diplômée en reconversion professionnelle (Data Analysis).

- **Objectif :** Valider son employabilité après une formation intensive.
- **Frustration :** Noyée sous des offres aux exigences floues ou exagérées (ex: 5 ans d'expérience pour un junior).

> *« Les offres demandent 5 ans d'expérience pour un poste junior, c'est impossible de savoir sur quoi faire l'effort d'apprentissage. »*

Faits vs Suppositions

- **Supposition (À vérifier) :** Les étudiants ne lisent pas les offres en détail pour analyser les compétences.
  Plan de vérification : 5 entretiens courts auprès d'élèves ingénieurs observant leur comportement face aux offres.
- **Fait (Avéré) :** Les recruteurs utilisent des mots-clés spécifiques (Power BI, Python, SQL) pas toujours explicités ou valorisés de la même manière dans les CV juniors.
- **Supposition (À vérifier) :** Les candidats suivront une micro-formation ciblée si leur lacune exacte est identifiée.
  Plan de vérification : Proposer un test sur landing page et mesurer le taux de clic vers les formations.

> **Question HMW (How Might We) :**
> « Comment pourrions-nous aider les étudiants et jeunes diplômés à identifier les compétences qui leur manquent par rapport aux attentes du marché de l'emploi afin de mieux préparer leur insertion professionnelle ? »

Question Métier (CRISP-DM Phase 1)

Décision / Action : Permettre au candidat d'identifier précisément les écarts de compétences entre son profil et une offre cible afin de prioriser ses efforts d'apprentissage (auto-formation/certifications) avant de postuler.

Cible : Les étudiants et jeunes diplômés en phase d'insertion professionnelle.

2. PARTIE 2 : IDÉER & CONVERGER

> **Phrase-Concept Validée :**
> « SkillMatch propose une analyse comparative CV/offres d'emploi à destination des étudiants et jeunes diplômés pour identifier les compétences manquantes et recommander des pistes de progression, contrairement aux sites de recherche d'emploi traditionnels (LinkedIn, Indeed) qui se contentent de lister les offres sans expliquer les refus. »

3. PARTIE 3 : CANVAS PROPOSITION DE VALEUR

Profil Client (Le Cercle)	Carte de Valeur (Le Carré)
Tâches (Jobs) : • Rédiger et adapter son CV pour chaque offre. • Rechercher des offres sur plusieurs plateformes. • Identifier les raisons d'un rejet de candidature. **Frustrations (Pains) :** • Manque de visibilité sur l'adéquation réelle du profil. [?] • Sentiment de perdre du temps sur des offres inadéquates. • Difficulté à prioriser les compétences à apprendre. [?] **Gains visés :** • Gagner du temps lors de la préparation des postulations. • Obtenir un plan d'action clair pour se former. • Maximiser les chances d'entretien.	**Produits et Services :** • Importation de CV au format PDF. • Moteur de matching sémantique NLP. • Tableau de bord compétences maîtrisées / manquantes. **Analgesiques (Pain Relievers) :** • Évite les candidatures aveugles via un score objectif. • Lecture directe des écarts CV vs Offre. **Créateurs de Gains (Gain Creators) :** • Recommandation de formations ciblées. • Mise en valeur immédiate des points forts du profil.

4. PARTIE 4A : CHARTE DE PROJET (README.MD)

Objectif SMART

- **Spécifique :** Développer un prototype fonctionnel de matching CV/Offre analysant les compétences et affichant un plan de progression.
- **Mesurable :** Précision d'extraction de 80% sur 50 CVs de test ; temps d'analyse < 3 secondes.
- **Atteignable :** Stack technique maîtrisée (Python, FastAPI, spaCy, React).
- **Réaliste :** Focalisé exclusivement sur l'analyse et le conseil (sans IA générative lourde ni gestion d'offres).
- **Temporel :** Prototype finalisé et déployé à la fin de la séance académique.

Périmètre (Scope) & Parties Prenantes

Inclus vs Exclu	Matrice Pouvoir / Intérêt
Inclus : Import PDF, extraction automatique de compétences, comparaison avec une offre, score de matching, identification des lacunes et recommandations. **Exclu :** Candidature automatique, mise en relation recruteurs, suivi de candidatures, génération de CVs.	• **Étudiants (P. Faible / I. Fort) :** Utilisateurs. Stratégie : Tests d'ergonomie. • **Équipe MSc Data (P. Fort / I. Fort) :** Réalisation. Stratégie : Pilotage Git/Scrum. • **Jury / Enseignants (P. Fort / I. Fort) :** Évaluation. Stratégie : Respect strict des jalons.

Arbitrage du Triangle d'Or

En cas de contrainte de temps, nous sacrifierons le **délai** sur les fonctionnalités secondaires afin de garantir la **qualité** de l'algorithme de matching et la **cohérence** de la proposition de valeur.

5. PARTIE 4B : DÉMARCHE CRISP-DM & SPÉCIFICATIONS DATA

Phase CRISP-DM	Description & Choix Techniques
1. Business Understanding	**Question métier :** Quelles compétences manquent sur le CV pour un poste ciblé ? **Succès :** Taux d'acceptation des recommandations > 75%.
2. Data Understanding	CVs PDF anonymisés, textes d'offres (JSON/Texte), référentiel de compétences (skills Data). Faible volume, traitement local.
3. Data Preparation	Nettoyage PDF (PyMuPDF), suppression des stop-words, lemmatisation avec `spaCy`, dictionnaire de synonymes (« PowerBI » = « Power BI »).
4. Modeling	**Approche :** NLP déterministe / sémantique (TF-IDF & similarité cosinus via `scikit-learn` / `spaCy`). *Pourquoi pas d'IA générative ?* Approche plus rapide, explicable, sans coût d'API et évaluable rigoureusement.

Phase CRISP-DM	Description & Choix Techniques
5. Evaluation	**Métrique technique :** Similarité cosinus > 0.6. **Métrique métier :** > 80% des lacunes correctement identifiées vs analyse humaine.
6. Deployment	Application Web (Frontend React, API FastAPI). Suppression des données en fin de session (Conforme RGPD).

Gestion des risques & RGPD : L'étape la plus risquée est l'extraction propre des textes PDF hétérogènes. Un retour d'expérience (40% du temps) est prévu entre la préparation de données et la modélisation. Côté RGPD, le consentement est demandé à l'upload et aucun fichier nominatif n'est conservé.

6. PARTIE 5 : SPÉCIFICATION DU MVP & USER STORIES

Hypothèse la Plus Risquée

« Nous pensons que les étudiants utiliseront un outil d'analyse pour identifier leurs lacunes techniques. Nous le validerons si au moins 70% des testeurs cliquent sur au moins une recommandation de formation. »

User Stories (Format Given / When / Then)

User Story 1 : Importation et extraction (PyMuPDF)
En tant qu' étudiant, *je veux* importer mon CV PDF *afin d'* extraire mes compétences.

- **Critère 1 :** Étant donné la page d'accueil, quand je glisse-dépose un PDF valide, alors le texte est extrait et un message de succès s'affiche.
- **Critère 2 :** Étant donné un fichier non-PDF, quand je l'importe, alors un message d'erreur explicite s'affiche.

User Story 2 : Matching & Lacunes (TF-IDF / spaCy)
En tant qu' utilisateur, *je veux* comparer mon profil à une offre *afin d'* obtenir mon score et mes lacunes.

- **Critère 1 :** Étant donné mon CV analysé, quand je sélectionne une offre et clique sur "Lancer le matching", alors le score (%) s'affiche avec la répartition "Maîtrisées" / "Manquantes".
- **Critère 2 :** Étant donné un CV sans compétences détectées, quand je lance l'analyse, alors une alerte m'invite à vérifier mon fichier.

User Story 3 : Responsabilité & RGPD (Obligatoire)
En tant qu' utilisateur soucieux de ma vie privée, *je veux* donner mon consentement *afin de* protéger mes données.

- **Critère 1 :** Étant donné l'interface d'upload, quand j'arrive sur la page, alors une mention explicite précise qu'aucune donnée n'est stockée à des fins commerciales.
- **Critère 2 :** Étant donné la fin de session, quand je ferme la page, alors le CV est purgé du serveur.